

-PenuX-Psychosis EarlyDetection: Simulation Study

-PenuX-Psychosis EarlyDetection: תרגיל מתודולוגי בהשוואת ~12,000 מודלים על נתונים מדומים

אזהרה קריטית — לקרוא לפני כל השאר

המאמר הזה אינו מבוסס על נתוני חולים אמיתיים. כל התוצאות המספריות כאן (AUROC, דירוגי מודלים, השוואות בין משפחות אלגוריתמים) מתארות עד כמה מודלים הצליחו לשחזר **אות מלאכותי שהוזרק בכוונה** לתוך מאגר נתונים מדומה (**simulated**) — לא ממצא קליני אמיתי, לא שחזור של מחקר אמיתי, ולא ראייה לכך שבדיקות מעבדה שגרתיות באמת מנבאות פסיכوزה. שום דבר כאן לא נבדק על אדם אמיתי, לא אושר אתית, ואסור שימש לכל החלטה רפואית, אבחנתית, ביטוחית או אחרת. ראו [docs/dataset_landscape.md](#) להסבר המלא מדוע לא נמצא מאגר נתונים אמיתי מתאים לשאלה הזו.

1. רקע והקשר

הבקשה המקורית לפרויקט זה הייתה לבחון זיהוי מוקדם של התקף פסיכוטי ראשון, עד 24 חודשים לפני הופעת סימנים קליניים, תוך שימוש בבדיקות מעבדה שגרתיות (לא ביומרקרים פסיכיאטריים ייעודיים, לא הדמיה, לא בדיקות גנטיות) ומרחב השוואה גדול של כ-12,000 מודלים — בהמשך ישיר למתודולוגיה שפותחה בפרויקט האחות `PenuX-AP-Severity`.

בדיקה יסודית (מתועדת ב- `docs/dataset_landscape.md`) העלתה **שאין כיום מאגר נתונים ציבורי וזמין** שתואם בדיוק את השאלה הזו — בדיקות מעבדה שגרתיות, עם פער זמן אמיתי של עד 24 חודשים לפני אבחנת פסיכוזה ראשונה, בגישה פתוחה. הקרוב ביותר בפועל:

- מחקר (2026) *Frontiers in Medicine* על 180 חולי סכיזופרניה בפרק ראשון מול 214 ביקורת, המשתמש בדיוק בסוג הנתונים המבוקש (בדיקות דם שגרתיות) — אך הבדיקות שם נאספו **בזמן** האבחנה הראשונה, לא 24 חודשים לפני, וגישה לנתונים המדויקים לא אושרה (גישה חסומה ל-*Frontiers* ול-PMC כאחד).
- מודל (Lancet Digital Health) *DETECT* שכן מדגים זמן-הקדמה אמיתי (כשנה לפני האבחנה) — אך מבוסס נתוני תביעות/רשומות רפואיות קנייניים, לא נתונים פתוחים.
- *UK Biobank* הוא המסלול הריאלי היחיד לשאלה הזו בפועל, אך דורש תהליך אישור פורמלי שאינו ניתן להשלמה בתוך session עבודה בודד.

בהתייעצות עם המשתמש, הוחלט לא להמתין לגישה למאגר אמיתי, אלא **לבנות מאגר מדומה במפורש**, המבוסס על טווחי ייחוס קליניים כלליים וכיוונים (לא ערכים) המדווחים בספרות הכללית — ולא על הנתונים המדויקים של *Frontiers* 2026, מכיוון שהמאמר המלא לא היה נגיש. המטרה: לבדוק את הצינור (pipeline) וההתנהגות של מרחב מודלים ענק על בעיה בגודל ובמבנה דומה, לא להפיק ממצא קליני.

2. הנתונים המדומים

נבנה מאגר סינתטי בגודל 394 שורות (180 "מקרה" + 214 "ביקורת", תואם לגדלי המדגם המדווחים ב-*Frontiers* 2026), עם 6 תכונות (בדיקות מעבדה שגרתיות): Arg (ארגינין), TP (חלבון כללי), ALP (פוספטאז אלקליין), HDL, UA (חומצת שתן), LDL. לכל תכונה נקבע ממוצע וסטיית תקן נפרדים לקבוצת ה"מקרה" וה"ביקורת" (ראו `src/penux_psychosis/simulate_data.py`), עם

הזזות קטנות ומכוונות בכיוונים הנפוצים בספרות הכללית (HDL נמוך יותר, LDL גבוה יותר בקבוצת ה"מקרה") — **לא ערכים שנלקחו מתוך מאמר ספציפי כלשהו**. לכל שורה יש עמודת `is_simulated=True` כמנגנון הגנה מפורש, וסקריפט ה-benchmark מסרב לרוץ אם דגל זה אינו קיים.

3. מתודולוגיה

נבנה zoo של **11,903 קונפיגורציות מודל** (יעד: כ-12,000), הכולל:

משפחה	קונפיגורציות	הערה
Torch DNN (from-scratch, sklearn-compatible wrapper)	6,615	הרוב המכריע של המרחב
XGBoost (רגיל + DART)	1,768	
LightGBM (רגיל + DART/GOSS)	1,384	
CatBoost (רגיל + Plain)	760	
Random Forest / Extra Trees (כולל "huge trees")	344	
Gradient Boosting (scikit-learn)	400	
SVM, KNN, Logistic Regression ועוד	630~	

בשונה מ-PenuX-AP-Severity, **הושמטה משפחת ה-1D-ConvNet**: עם 6 תכונות בלתי-תלויות בלבד, התייחסות אליהן כ"רצף" הניתן לקונבולוציה אינה בחירה ארכיטקטונית משמעותית, וגם גרמה לשגיאות ממדים בעבודה מוקדמת יותר בפרויקט המקביל.

כל קונפיגורציה הוערכה עם **fold Stratified Cross-Validation-5** זהה, ותחזיות out-of-fold שימשו לחישוב AUROC.

3.1 בעיית ביצועים אמיתית שנתקלנו בה ותוקנה

אומדן ראשוני להרצת כל 11,903 המודלים באופן טורי עמד על **כ-9.4 שעות** — לא מעשי. איתרנו את הבעיה בפועל (לא רק השערה): **CatBoost** היה המשפחה האיטית ביותר, עם fits בודדים שנמשכו עד **28 שניות** ב-iterations=1800-2500 — בדיוק אותה תבנית קנה-מידה פתולוגית שכבר תועדה ב-PenuX-AP-Severity. גם XGBoost DART ו-LightGBM DART GOSS הראו האטה דומה (עד 20 שניות ל-fit בודד) בגלל ה-dropout שמוכפל עם מספר האומדנים. הפתרון: הגבלת `iterations / n_estimators` המקסימלי ל-500-600 בכל המשפחות האיטיות (ללא שינוי במספר הקונפיגורציות הכולל — רק בערכים הספציפיים), והרצה מקבילית **בין** מודלים (4 workers, joblib/loky).

במקום טורית, תוך נעיצת ה-thread pool הפנימי של כל אומדן ל-1 (למניעת אותו "thread oversubscription bug" שגרם להאטה פי 100+ בפרויקט המקביל כשהופעלו שני רבדים של מקביליות בו-זמנית). התוצאה: זמן ריצה בפועל ירד מ-9.4 שעות ל-~60 דקות.

תוקן גם באג אמיתי: ה-wrapper המותאם-אישית סביב PyTorch לא ירש מ-ClassifixerMixin / sklearn.base.BaseEstimator, וכשל בשקט על כל 6,615 הקונפיגורציות מבוססות-Torch (למעלה ממחצית המרחב!) בגלל דרישת __sklearn_tags__ החדשה ב-scikit-learn 1.9. זוהה ותוקן לפני ההרצה המלאה.

4. תוצאות

הרצת 11,903 הקונפיגורציות הושלמה ללא שגיאות (11,903/11,903 "ok"). התפלגות ה-AUROC על פני כל המרחב: מינימום 0.277, חציון 0.760, מקסימום 0.809.

4.1 המודל המדורג ראשון

(Gradient Boosting של sklearn) gbd_tsklearn_n90_lr0.05_sub0.7, 90 עצים, (learning rate 0.05, subsample 0.7): **AUROC=0.809**. שימו לב שזהו מודל עם מספר עצים קטן יחסית (90) — לא אחת הקונפיגורציות "הענקיות" — עדות נוספת לכך שעל מדגם קטן (394 שורות), מודלים גדולים מדי לא רק שלא עוזרים, אלא באמת רק מוסיפים זמן ריצה.

4.2 טבלת המשפחות המובילות

מס' קונפיגורציות	ממוצע AUROC	מקסימום AUROC	משפחה
400	0.7729	0.8092	Gradient Boosting (sklearn)
27	0.7978	0.8089	"Huge trees" (RF/Extra Trees) (הגבלת עומק)
768	0.7530	0.8080	XGBoost DART
64	0.7767	0.8066	KNN
600	0.7796	0.8063	CatBoost
117	0.7707	0.8054	Extra Trees
1,000	0.7632	0.8053	XGBoost
6,615	0.6530	0.8009	Torch DNN

משפחה	מקסימום AUROC	ממוצע AUROC	מס' קונפיגורציות
Decision Tree (בודד)	0.7349	0.6835	50
Perceptron	0.7253	0.6465	24

מגמה בולטת: משפחות ה-GBDT ensemble על גווניו, Random Forest, (Extra Trees, KNN) מובילות בעקביות; רשתות ה-DNN המבוססות-Torch, למרות שהן הרוב המכריע של המרחב (6,615 מתוך 11,903 קונפיגורציות), משיגות ממוצע נמוך משמעותית (0.653) — סימן ל-underfitting נרחב בקונפיגורציות עם קצב-למידה/עידן-אימון נמוכים מדי, כפי שניתן לראות ברשימת "הגרועים ביותר" (כל העשרה התחתונים הם torch_dnn עם $lr=0.0001$).

4.3 בדיקת מובהקות סטטיסטית

בהשוואה ל-baseline של רגרסיה לוגיסטית פשוטה (`logreg_C1_None_lbfgs`), המודל המדורג ראשון ($AUROC=0.8092$) **לא עבר מובהקות סטטיסטית קונבנציונלית** (Hanley-McNeil, מבחן z חד-כיווני): $z=0.91$, $p \approx 0.18$. כלומר — גם בתוך הסימולציה עצמה, ההבדל בין המודל הטוב ביותר לבייסליין הפשוט אינו גדול מספיק כדי להיחשב שונה מרעש סטטיסטי, במדגם בגודל 394. זהו ממצא כן, לא מוסתר, בדיוק כפי שנעשה בפרויקט `PenuX-AP-Severity`.

5. מגבלות (בנוסף לאזהרה הכללית בראש המסמך)

1. **הנתונים מדומים לחלוטין.** שום ערך מספרי כאן אינו נגזר ממדידה אמיתית על אדם כלשהו, חולה או בריא.
2. **גם טווחי הייחוס עצמם הם כלליים/אילוסטרטיביים**, לא מכילים למאמר Frontiers 2026 הספציפי (שהגישה אליו נחסמה) ולא לשום מקור אחר בעל מספרים מדווחים.
3. תוצאה של $AUROC=0.81$ בסימולציה **אינה מעידה דבר** על יכולת ניבוי אמיתית של פסיכומטריה מעבדה — היא מעידה רק על כך שהצינור (pipeline) מסוגל לזהות אות שהוזרק בכוונה.
4. לא בוצע כיול הסתברויות (calibration), ולא נבדקה יציבות התוצאות מול הזרעה אקראית שונה (seed sensitivity).

5. הפרויקט לא יתקדם לשלב נוסף כלשהו של "ממצא קליני" על בסיס הסימולציה הזו.

6. מה כן נלמד (תרומה מתודולוגית, לא קלינית)

- מרחב השוואה של כמעט 12,000 מודלים על נתונים טבלאיים קטנים (6 תכונות, 394 שורות) הוא בר-ביצוע בזמן ריצה סביר (~60 דקות) על 4 ליבות, בתנאי שמזהים ומתקנים במפורש משפחות בעלות קנה-מידה פתולוגי (CatBoost/DART בפרט).
- הבאג ב-wrapper של PyTorch (חוסר ירושה מ-BaseEstimator) הוא תזכורת חשובה: כשליש עד מחצית ממרחב מודל גדול יכול "להיכשל בשקט" (silent failure) אם לא בודקים תוצאות ביניים לפני הרצה מלאה — בדיוק מה שקרה כאן, ותוקן בזכות בדיקת smoke-test על מדגם קטן לפני ההרצה המלאה.
- שוב, כמו בפרויקט האחות, מודלים "ענקיים" (עומק/מספר עצים גדולים) לא ניצחו — המודל המוביל השתמש ב-90 עצים בלבד.

7. עדכון: ניסיון נוסף לאתר נתונים אמיתיים (Kaggle וכו')

לאחר פרסום הגרסה הראשונה של המאמר הזה, התבקש ניסיון נוסף, יסודי יותר, לאתר מאגר נתונים אמיתי — כולל בדיקה מפורשת של Kaggle. הממצאים החדשים:

7.1 חסימת רשת מאומתת, לא רק "לא נמצא"

בדיקה ישירה גילתה ש-Kaggle וכל תתי-הדומיין של NCBI (כולל GEO) חסומים במפורש ברמת מדיניות הרשת של הסביבה הזו (תגובת 403 policy/denial בבדיקת curl ישירה ובבדיקת סטטוס ה-proxy של הסביבה). זהו הבדל מהותי: גם אם קיים מאגר נתונים ציבורי מושלם באחד המקורות הללו, לא ניתן להוריד אותו ישירות מהסביבה הזו — זו מגבלת גישה טכנית ממשית, לא רק "לא מצאנו". בנוסף, אתרי הוצאות לאור אקדמיות (Frontiers, Nature, PMC) חוסמים ניסיונות גישה אוטומטיים (הגנת Cloudflare), כך שגם כאשר מאמר מדבר על "בדיקות שגרתיות", לא ניתן היה לאמת בפועל את הצהרת זמינות הנתונים שלו.

7.2 מחקר נוסף שנמצא – עם זמן-הקדמה אמיתי, אך ללא נתונים זמינים

אותר מחקר מ-2015 ב-Translational Psychiatry: "Development of a blood-based molecular biomarker test for identification of schizophrenia before disease onset" – 957 פאנל של 26 ביומרקרים, עם **זמן-הקדמה אמיתי של עד שנתיים** לפני האבחנה (ההתאמה הכי טובה שנמצאה מבחינת התזמון המבוקש). עם זאת: לא נמצא קישור למאגר נתונים גולמי (סביר שמעולם לא הופקד – המאמר פורסם ב-2015, לפני שרוב כתבי העת חייבו הפקדת נתונים), וכמעט כל 26 הביומרקרים הם אנליטים של immunoassay מיוחד (ציטוקינים, vWF, VCAM-1 ועוד) – לא בדיקות שנכללות בפאנל דם שגרתי רגיל, כך שגם אם הנתונים היו זמינים, ההתאמה ל"בדיקות שגרתיות" הייתה חלקית בלבד.

7.3 מסלול נתונים אמיתי אחד שכן קיים – אך חסום זמנית

UK Biobank נותר המסלול המציאותי היחיד שתואם בפועל את שני התנאים גם יחד (בדיקות דם שגרתיות בזמן הגיוס + אבחנות פסיכיאטריות מקושרות שעלולות להתרחש שנים מאוחר יותר). עם זאת, **UK Biobank אינו מקבל כרגע בקשות גישה חדשות** – לפי האתר הרשמי שלהם, הגשות מושהות בעקבות שינויים בפלטפורמה, וצפויות להיפתח מחדש רק "בסוף 2026". תועד תהליך ההגשה המלא, כולל דרישות הזכאות (קורות חיים, עד 5 מספרי אסמכתא מ-PubMed של פרסומים קודמים – פוטנציאלית מכשול אמיתי לחוקר עצמאי ללא רקורד פרסומים – ותעודת השלמת קורס MRC בסודיות והגנת מידע), ב-[docs/uk_biobank_access_plan.md](https://docs.uk_biobank_access_plan.md), מוכן לפעולה ברגע שההגשות ייפתחו מחדש.

7.4 מסקנה

שום דבר מהאמור לעיל לא משנה את המסקנה הבסיסית: **אין כרגע נתונים אמיתיים זמינים לפרויקט הזה**, וההחלטה להשתמש בנתונים מדומים ומתויגים במפורש (סעיפים 1–6 לעיל) הייתה, ונשארת, הבחירה האחראית היחידה בנתונים העומדים לרשותנו כעת.